李远鹏

+(86) 136-6256-6313 liyp2001@outlook.com yuanpeng-li.github.io github.com/Yuanpeng-Li lyp13662566313

强化学习 | 大模型后训练（GRPO、RLHF）**| 多任务学习 | VLA 模型 | AI 智能体与 MCP**
研究方向：强化学习与多任务优化，从小型控制策略到 VLA 模型和 LLM

教育背景

加州大学尔湾分校（UC Irvine） **美国加州，尔湾**
统计学博士（*PhD*）；导师：*Annie Qu* 教授、*Rui Miao* 教授；研究生助教：*STATS 7*、*67*、*110*、*120C*、*205P* *2024.09 – 2028.05*（预计）

加州大学尔湾分校（UC Irvine）暑期研究 **美国加州，尔湾**
研究助理（*RA*），统计系；导师：*Annie Qu* 教授 *2023.06 – 2023.09*

吉林大学 · 数学学院 **中国，长春**
理学学士，数学与应用数学专业 *2020.09 – 2024.06*

代表性论文

TOPPO: Rethinking PPO for Multi-Task Reinforcement Learning with Critic Balancing. *NeurIPS 2026*
Yuanpeng Li, Gefei Lin, Annie Qu, Rui Miao. arXiv:2605.11473，第一作者。

科研经历

高效多任务强化学习研究（TOPPO）[代码] **美国加州，尔湾**
第一作者，*NeurIPS 2026* 已接收；导师：*Annie Qu* 教授、*Rui Miao* 教授 *2026.04*

- 逐任务分析梯度，发现价值网络梯度病态是多任务 PPO 的关键瓶颈：简单任务主导价值网络学习，难任务学不动。
- 据此提出 *Critic Balancing*：逐任务 PopArt、带 LayerNorm 的价值网络、价值网络用 FairGrad、策略网络用 PCGrad；证明了 $\alpha = 1$ 时对各任务梯度做任意正数缩放，FairGrad 的更新不变，并开发了投影牛顿求解器，速度是 SciPy 的 83 倍。
- 在 Meta-World+ MT50 上达到 SOTA（平均 90.9%、最差 10 个任务 56.5%），超过最强基线 ARS-LN-1024（85.7%、43.3%），参数量仅为其 1/22.7，只用 28% 的步数就追平了它的最终成绩。
- 把 Critic Balancing 推广到双目标的 AMP 人形机器人任务，动作风格 FID 降低 76%。

把 TOPPO 扩展到大模型：VLA 与 LLM 强化学习 **美国加州，尔湾**
导师：*Annie Qu* 教授、*Rui Miao* 教授 *2026.09*

- 用 RLinf 做 3.3B π_0 VLA 模型的强化学习微调，并用 verl、vLLM 和 FSDP2 搭建 LLM 的 GRPO/PPO 训练流程，以自己用 vLLM 部署的 Nemotron-3-Super-120B 裁判模型做奖励。
- 与小网络不同，常规的整网梯度手术在 π_0 和 LLM 上都没有明显效果，由此引出下面的分块梯度研究。

深层多任务网络的分块梯度平衡 **美国加州，尔湾**
导师：*Annie Qu* 教授、*Rui Miao* 教授 进行中

- 在同一个 PyTorch 训练框架里评测 26 种多任务梯度方法，复现了 NYUv2、CelebA、QM9 上已发表的结果。
- 发现梯度主要集中在少数很小的前层，所以 FairGrad 计算任务权重用的全网络 Gram 矩阵基本只反映这些层；而在 QM9 上，几个能量目标的梯度只在最后的 readout 层才有区别，全网络 Gram 矩阵几乎看不到。
- 提出 norm 诱导的分块 kernel，平衡各模块对 FairGrad 任务权重的贡献：在 QM9 图 Transformer 上把 $\Delta m\%$（相对单任务模型的平均差距）从 27.7 降到 9.6。

考虑运行时长不确定性的 HPC 作业调度 **美国加州，尔湾**
合作：*Rui Miao* 教授 进行中

- 用 Python 和 C 写了 Slurm 模拟器 slurmsim，作业启动顺序与真实 Slurm 一致，抽样的作业优先级 99.9% 完全相同。
- 改用 Kaplan–Meier 运行时长估计设置每个作业的 `--time-min`（backfill 规划时用的时长），用户时限仍作硬上限：模拟中平均周转时间缩短 8–18%，美国国家实验室超算日志的回放模拟中缩短 8%，超时几乎不增加。

项目经历

RunFleet & **Run-Skills** | *Python, Bash, Slurm, MCP*

- 终端看板 RunFleet 用 SSH 查看多个 Slurm 集群的作业和 GPU 并标出失败原因；Run-Skills 让 Claude Code 提交作业。

Gradescope MCP | *Python, MCP, uv*

- 开发了一个 MCP 服务器，让 AI 智能体可以在 Gradescope 上批改作业、修改评分标准，每次写入都先预览，经人确认后才执行。

获奖荣誉

- 加州大学尔湾分校统计系**研究生差旅奖**（2,500 美元） *2026.11*
- 中国大学生数学竞赛**全国三等奖**；吉林省大学生数学竞赛**省级二等奖** *2021.12*

技能

- **方法：**强化学习（PPO / GRPO）、RLHF/RLAIF、多任务学习（PCGrad、FairGrad、MGDA）、LoRA/PEFT
- **训练框架：**PyTorch, Hugging Face Transformers, vLLM, verl, FSDP, RLinf
- **智能体工具：**MCP 服务器、Claude Code / Codex 技能与插件
- **训练基础设施与工程：**Python, C, Git, Docker, Linux, Slurm, Ray, W&B, uv, pytest, 远程服务器训练与实验管理